AI ENGINEER PORTFOLIO

PORTFOLIO

사용자의 숨은 흐름을 읽고 ,
최적의 기술 구조를 설계하는 AI 엔지니어

AI 엔지니어 지원자
강건재

PROFILE

Profile



강건재

Kang Geon Jae · 1995.08.12

010-4120-2283
kgj200401@gmail.com

Education & Career

2026.08 ~ 현재	경기 AI 멤버십 채용연계형 교육
2025.07 ~ 2026.06	삼성청년 SW·AI 아카데미 (Python Track)
2023.11 ~ 2025.07	영어강사 (중 2~ 고 2 내신 전담)
2015.03 ~ 2023.08	한국항공대학교 항공전자정보공학부 전공

Certification & Award

2026.03	OPIc IH
2026.06	데이터 분석 준전문가 (ADsP)
2026.06	SQL 개발자 (SQLD)
2026.09	NVIDIA "Building AI Agents with Multimodal Models"
Award	**2026 삼성청년 SW·AI 아카데미 AI 챌린지 우수상**

Skills

AI / ML	LLM, PyTorch, Hugging Face, YOLO, OpenCV, RAG
Language & Frontend	Python, JavaScript, HTML, CSS, Vue, React
Backend & DB	FastAPI, Django, SQLite
Tools	Git, GitHub, Jira, Figma, Notion

CONTENTS

목차

MAIN PROJECT 주요 프로젝트 3

01 **VQA AI Model**
이미지 기반 VQA 멀티모달 AI 모델
2025.10 P. 6–11

02 **MEERUS FARM**
지능형 스마트팜 통합 관리 솔루션
2026.01 ~ 02 P. 12–16

03 **NightWatch**
야간 자율순찰 시스템
2026.03 ~ 04 P. 17–21

MINI PROJECT 미니 프로젝트 2

M1 **Smart Cart**
AI 비전 기반 스마트 마트카트
P. 23–24 · 2026.09

M2 **AI 도슨트**
국립중앙박물관 AI 도슨트
P. 25–26 · 2026.09 ~ 10

INTRO

Profile P. 2

Project Summary P. 4

PROJECT SUMMARY

프로젝트 한눈에 보기

PROJECT 01 2025.10 · 4 인

VQA AI Model

이미지와 질문을 함께 이해해 정답을 예측하는 멀티모달 VQA 모델 개발

Qwen3-VL-8B | LoRA | Prompting

ROLE AI Model Fine-tuning · Data

Accuracy 0.96296
Leaderboard Top 11 (지역 2 위)

PROJECT 02 2026.01~02 · 5 인

MEERUS FARM

Vision AI 와 LLM 을 활용한 스마트팜 병해 진단 및 AI 리포트 시스템 구축

YOLO26n | TensorRT | RAG

ROLE LLM · RAG · Vision AI

mAP50 0.90
AI 리포트 자동 생성

PROJECT 03 2026.03~04 · 6 인

NightWatch

Vision AI 기반 이상 상황 탐지와 AI 관제 리포트 자동 생성 시스템 구축

ROS2 | YOLO11n | EfficientNet-B0

ROLE Vision AI · LLM

자물쇠 탐지 mAP50 0.995 (가상환경)
상태 분류 검증 정확도 100%

MINI PROJECT 01

Smart Cart

2026.09 · 5 인

AI 비전으로 상품을 인식해 장바구니 금액을 계산하고 , 보유 재료로 만들 수 있는 요리를 추천하는 서비스

YOLOv8n | FastAPI | Roboflow

ROLE Backend · Vision AI 통합

Precision 94.70%
10 종 상품 인식 + 5 종 요리 추천

MINI PROJECT 02

AI 도슨트

2026.09 ~ 10 · 5 인

카메라로 유물을 인식해 관람객 유형별 해설과 실시간 Q&A 를 제공하는 국립중앙박물관 AI 도슨트

EfficientNet-B0 | Ollama | RAG

ROLE 팀장 · PM · 데이터셋 구축

Vision 정확도 99.61%
LLM 응답 3.5~4.3 초

MAIN PROJECT

MAIN PROJECTS

AI 모델 · 서비스 개발 주요 프로젝트 3 건

01 VQA AI Model

02 MEERUS FARM

03 NightWatch

OVERVIEW

이미지 기반 VQA 멀티모달 AI 모델

기간	팀 구성	담당 영역
2025.10	4 인 프로젝트	AI Model Fine-tuning · Data Analysis

프로젝트 개요

핵심 목표

이미지와 질문을 함께 이해하여 **정답을 예측하는 멀티모달 VQA 모델** 개발

도입 배경

데이터 분석 · 전처리 · 파인튜닝으로 **제한된 GPU 환경**에서도 효율적인 모델 구축

주요 기능

- Qwen3-VL-8B LoRA 파인튜닝
- Validation 기반 최적 Epoch 선정
- 프롬프트 엔지니어링으로 추론 방식 검증
- 이미지 데이터셋 확장 (Pixabay)

담당 역할 및 기여

- **모델 선정** : 다양한 VLM 후보 성능 비교 및 최종 모델 선정
- **파인튜닝** : Qwen3-VL-8B 에 LoRA 적용 , 학습 효율 · 성능 개선
- **성능 분석** : Validation 결과로 성능 저하 원인 분석 및 개선 방향 수립
- **프롬프트 엔지니어링** : 다양한 전략 실험 , 최적 추론 방식 검증
- **발표** : 최종 성과 발표



VQA 응답 예시 화면

0.963
Accuracy

11 위
254 팀 중 (지역 2 위)

TECH STACK

Qwen3-VL-8B | LoRA / QLoRA | Hyperparameter Tuning | Prompting | PyTorch | Unsloth

DEVELOPMENT ENVIRONMENT & AI PIPELINE

개발환경 및 AI Pipeline

실행환경

Google Colab 기반
Python 3.11 · Jupyter Notebook (.ipynb)

주요 라이브러리

PyTorch · Transformers · PEFT
Pandas · Bitsandbytes
Accelerate · Pillow

사용 모델

Qwen3-VL-8B

AI Pipeline

1 데이터 준비
- train.csv / test.csv 로드 (pandas)
- 이미지 경로 · 질문 · 보기 · 정답

2 프롬프트 구성
- SYSTEM_INSTRUCT + 질문 · 보기 4 개
- VQAMCDataset → messages 변환

3 Processor 처리
- apply_chat_template()
- input_ids · pixel_values · labels 생성

4 모델 파인튜닝
- LoRA + 4bit Quantization
- batch=1, GA=4

5 검증 (Validation)
- valid_loader 평가 · Loss 모니터링
- LoRA Adapter·Processor 저장

6 추론 (Inference)
- test.csv 순회
- model.generate()

7 후처리
- extract_choice()
- a/b/c/d 선택지 추출

8 최종 결과
- submission.csv 생성 (문제 ID· 예측정답)
- **Accuracy 0.96296**

TROUBLE SHOOTING 1

대규모 모델 학습 환경 구축

문제 정의 제한된 환경 (Google Colab 단일 GPU) 에서 **대규모 모델 학습 시 OOM(메모리 부족)** 발생

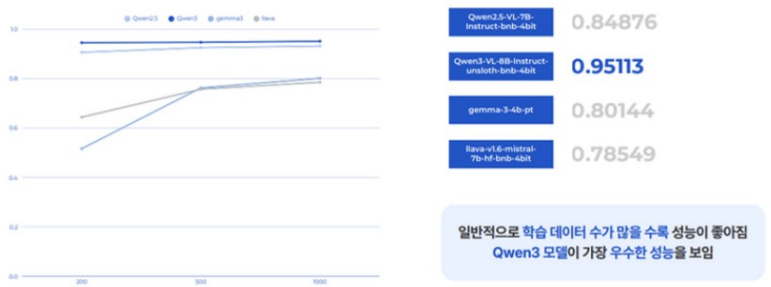
원인

- 대규모 VLM 은 GPU 메모리 요구량이 큼

해결

- **Unsloth 기반 LoRA·QLoRA** 파인튜닝 적용
- **4bit 양자화**로 가중치 정밀도를 낮춰 GPU 메모리 절약
- LoRA 로 핵심 파라미터만 업데이트해 학습 효율 극대화

멀티모달 모델 선정



후보 모델 성능 비교

결과 경량화 효율이 검증된 Unsloth 기반 모델을 후보군으로 성능을 비교하여 **최종 모델 Qwen3-VL-8B 선정**

Qwen2.5-VL-7B 정밀 OCR· 도표 인식	**Qwen3-VL-8B ✔️ 선정** 최신 비전 성능 , 멀티 태스크
gemma-3-4b 초경량 모델	**llava-v1.6-mistral-7b** VQA 튜닝 최적화

TROUBLE SHOOTING 2

하이퍼파라미터 튜닝

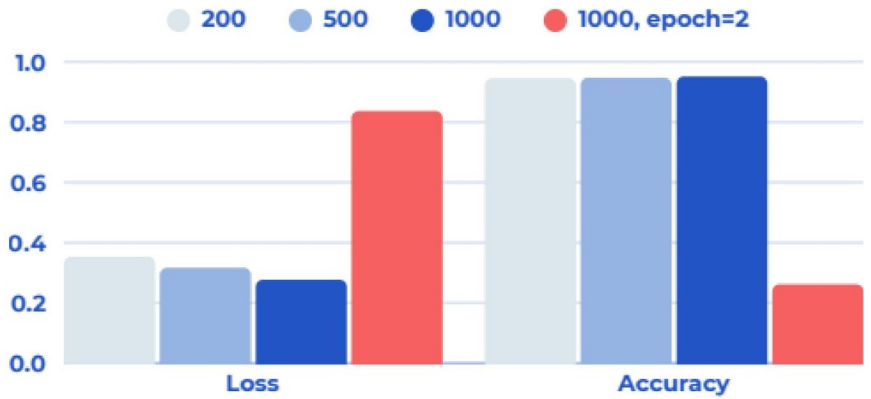
문제 정의 데이터 개수와 Epoch 를 늘릴수록 성능이 향상되었지만 , 일정 수준 이후 **Validation 성능이 감소하며 과적합** 발생

원인

- 학습 데이터 규모가 모델의 일반화 성능에 영향을 줌
- 과도한 학습으로 특정 데이터에 과적합

튜닝 항목

- **Learning rate** : 학습 데이터 양에 따라 다르게 설정
- **Weight decay** : 0.01 기본 , 과적합 시 증가
- **LoRA** : r(랭크) 가 클수록 표현력 · 정확도 ↑ , 과적합 위험 ↑ / α 는 r 과 동일 / dropout 은 과적합 시 0.05~0.1
- **데이터 개수 & Epoch** : 증가시킬수록 정확도 상승



데이터 수 · Epoch 별 Loss / Accuracy

결론 **Validation Loss 와 Accuracy 를 기준으로 최적 학습 지점을 선정**하여 과적합을 방지

TROUBLE SHOOTING 3

프롬프트 엔지니어링

문제 정의 다양한 프롬프트를 적용했지만 **성능이 개선되지 않거나 오히려 감소**하는 문제 발생

실험	예시	문제	원인	해결
이미지 · 텍스트를 자세히 보도록 지시	" 이미지 , 텍스트를 자세하게 보고 답변하세요 "	**성능 저하**	질문과 무관한 객체까지 함께 고려하여 핵심 특징을 놓침	질문과 보기 중심으로 추론하도록 프롬프트 간소화
가장 높은 확률의 보기 선택	" 확실치 않을 때는 , 보기의 확률이 가장 높은 것을 선택 "	**성능 향상 없음**	질문과 무관한 객체의 확률이 높아 오답 발생	추론 방식을 강제하지 않고 기본 프롬프트 유지
Few-shot 추가	질문 · 보기 · 정답 예시 2 건을 프롬프트에 포함	**성능 향상 없음**	사전 학습된 프롬프트 패턴으로 예시 추가 효과가 제한적	출력 형식 일관성 유지 용도로 활용

결과 다양한 프롬프트를 적용했지만 정확도 향상 효과는 제한적이었고 , **출력 형식의 일관성 유지**에만 효과가 있음을 확인
핵심 결론 : 프롬프트 수정만으로는 성능이 오르지 않으며 , **데이터 품질 개선과 모델 파인튜닝**이 정확도 향상에 더 큰 영향을 줌

RESULT & REFLECTION

성과 및 회고

0.96296

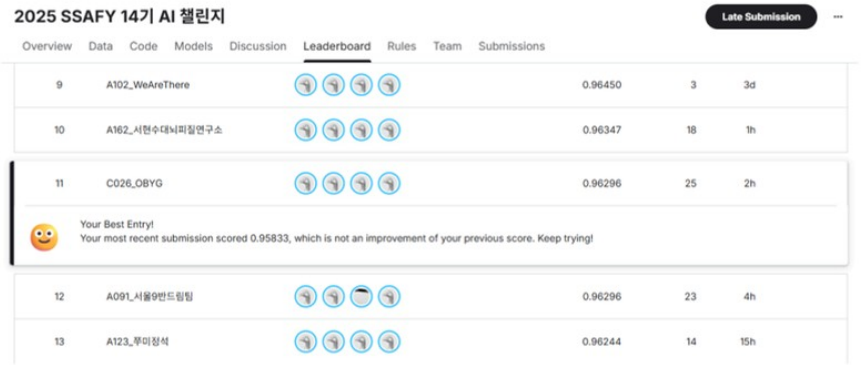
Accuracy

11 위

254 개 팀 중 (지역 2 위)

Qwen3-VL-8B

최종 선정 모델



2025 SSAFY 14 기 AI 챌린지 · 리더보드

아쉬웠던 부분

GPU 자원의 제약으로 더 큰 모델과 다양한 하이퍼파라미터 조합을 충분히 실험하지 못함

개선 방안

더 다양한 Vision-Language Model 과 데이터 증강 기법을 적용하여 일반화 성능을 비교 · 검증

깨달은 점

- 프롬프트 수정만으로는 성능이 크게 오르지 않았고 , **데이터 품질과 파인튜닝 전략**이 더 큰 영향을 줌
- 많은 실험보다 **원인을 분석하고 가설을 검증**하는 과정이 성능 개선에 더 중요

OVERVIEW

지능형 스마트팜 통합 관리 솔루션

기간	팀 구성	담당 영역
2026.01 ~ 2026.02 (6 주)	5 인 프로젝트	LLM · RAG · Vision AI

프로젝트 개요

핵심 목표

멀티모달 데이터로 농작물의 생육 환경을 분석하고 , **AI 병해 탐지와 생성형 AI 리포트**를 제공하는 스마트팜 관리 플랫폼 구축

도입 배경

실시간 환경 데이터 · 영상 분석 · 생성형 AI 를 결합해 농작물 상태를 직관적으로 확인하고 효율적으로 농장을 관리할 수 있도록 구축

주요 기능

- MQTT 센서 데이터 수신 및 모니터링
- AI 기반 병해 탐지
- LLM 기반 분석 리포트

담당 역할 및 기여

- **경량 RAG 컨텍스트 설계** : 키워드 필터링 기반 (논문 PDF 3 편) 으로 LLM 이 센서 데이터와 논문 정보를 함께 활용하도록 구현
- **GPT-4o-mini 리포트 생성** : 병해 위험도 및 대응 방안 리포트 생성
- **Vision AI 실시간 병해 탐지** : Jetson Orin Nano 에서 YOLO26n + TensorRT(FP16) 로 잿빛곰팡이병 탐지
- **프롬프트 엔지니어링** : 최적화로 응답 품질과 일관성 향상
- **AI 서비스 결과 발표** : 분석 결과와 서비스 흐름을 정리 · 발표

TECH STACK YOLO26n | TensorRT (FP16) | RAG | GPT-4o-mini | Django | React | MQTT | Docker Compose

DEVELOPMENT ENVIRONMENT & AI PIPELINE

개발환경 및 AI Pipeline

실행환경

Backend: Django 6 + DRF · Frontend: React 19 + Vite
Database: SQLite · Communication: MQTT
Deployment: Docker Compose

AI 환경

LLM: GPT-4o-mini (OpenAI Compatible API)
Vision AI: YOLO Detection + Segmentation
Data: MQTT Sensor + Vision 결과

AI Pipeline

1 MQTT 센서 수신
- 온도 · 습도 데이터 수신

2 Django 백엔드 반영
- 센서 값 DB 반영 (SQLite)

3 Vision AI 분석
- YOLO 병해 탐지
- Segmentation, severity 산출

4 센서 + Vision 통합
- 농장 단위로 전 구역 평균 계산
- JSON 컨텍스트 생성

5 키워드 필터링 RAG
- 논문 PDF 3 편 로드 · 텍스트 추출
- 키워드 포함 페이지 발췌 → 참고 문맥 구성

6 프롬프트 · LLM 호출
- 센서 +Vision 컨텍스트 + 논문 참고 문맥
- GPT-4o-mini

7 AI 리포트 생성
- 요약 · 위험도 · 원인 분석
- 권장 조치 및 관리 방안

8 DB 저장 · 대시보드
- Report 모델 저장 , 히스토리 조회
- 리포트 조회 · 시각화

TROUBLE SHOOTING 1

Vision 데이터와 RAG 를 활용한 LLM 리포트 개선

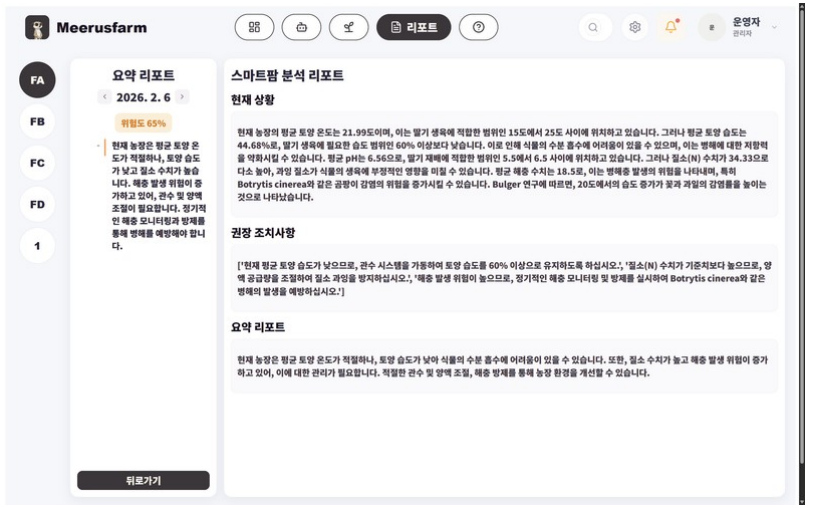
문제 정의 Vision AI 의 병해 위험도와 센서 데이터만으로는 **LLM 이 병해 원인과 대응 방안을 충분히 설명하지 못함**

원인

- Vision AI 는 병해 위험도 (severity) 만 , 센서는 온도 · 습도 등 환경 정보만 제공
- 병해에 대한 전문 지식이 없어 LLM 이 일반적인 답변을 생성

해결

- Vision 분석 결과의 severity 와 센서 평균 데이터를 **하나의 JSON 구조로 통합**
- **키워드 필터링 기반 경량 RAG** 로 논문 발췌문을 LLM 프롬프트에 포함
- 실시간 농장 데이터와 전문 지식을 함께 활용하는 컨텍스트 구성



MEERUS FARM · AI 분석 리포트 화면

결과 LLM 이 환경 정보 · 병해 위험도뿐 아니라 **논문 기반 전문 지식**을 함께 참고하여 , 농장 상태 분석 · 위험도 평가 · 대응 방안을 포함한 **종합 리포트**를 생성

TROUBLE SHOOTING 2

Jetson 환경 실시간 추론 최적화

문제 정의

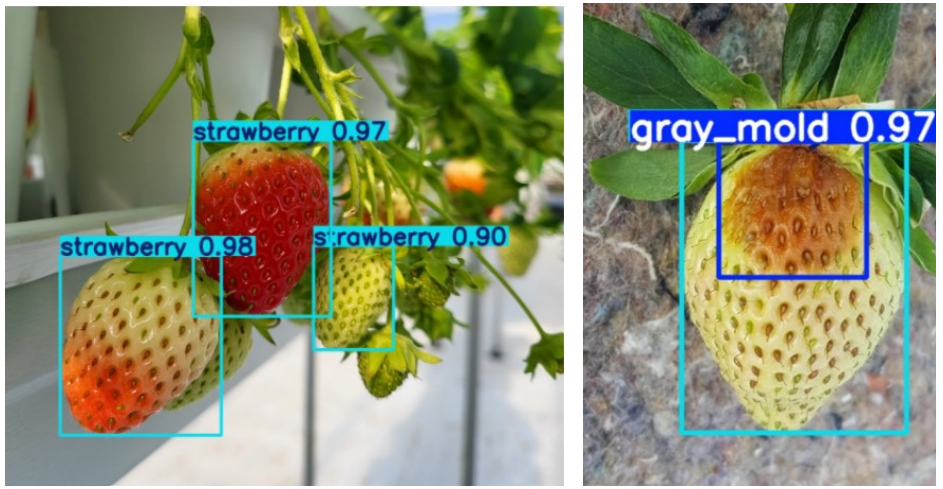
스마트팜 로봇은 Jetson Orin Nano 에서 카메라 영상으로 병해 (잿빛곰팡이병) 를 **실시간 판단**해야 했으나 , 일반 모델을 그대로 쓰면 **추론 지연**이 발생할 수 있음

원인

- Edge Device 는 서버 GPU 보다 연산 자원 · 메모리가 제한적
- 큰 Vision 모델을 FP32 로 추론하면 처리 속도가 느려 실시간 병해 판단에 부적합

해결

- 1 차 병해 판단에 경량 모델 **YOLO26 Nano** 적용
- **TensorRT FP16** 최적화로 연산량과 메모리 사용량 감소
- Jetson Orin Nano 에서도 빠른 추론이 가능하도록 구성



YOLO26 Nano 실시간 병해 탐지 결과

결과

Edge 환경에서도 **실시간 병해 판단**이 가능한 구조를 구축 . 병해 여부를 먼저 빠르게 판별한 뒤 필요 시 **정밀 분석 모델로 연결**할 수 있는 기반 마련

RESULT & REFLECTION

성과 및 회고

0.90

YOLO Detection 모델
mAP50(B)

FP16

TensorRT 적용
Edge 환경 추론 속도 최적화

주요 성과

- Vision 분석 결과와 센서 데이터를 통합한 **AI 리포트 자동 생성**
- **경량 RAG(논문 발췌)** 기반 전문 지식을 활용한 병해 원인 및 대응 방안 제공

아쉬웠던 부분

- OpenAI API 기반 리포트 생성이라 추론 비용 · 응답 속도에 한계
- GPU 자원을 Vision AI 에 우선 배정해 vLLM 자체 추론 서버는 구축하지 못함 (리포트 속도는 충분해 API 구조 채택)

개선 방안

- vLLM 으로 오픈소스 LLM 을 직접 서빙
- 임베딩 기반 검색으로 센서 · 병해 상황에 맞는 문맥을 찾도록 RAG 를 고도화하여 응답 품질 개선

깨달은 점

- 개별 모델 정확도뿐 아니라 **Vision AI · 센서 · RAG 를 하나의 컨텍스트로 연결하는 설계**가 서비스 성능을 좌우함
- 생성형 AI 는 **입력 컨텍스트 설계**가 품질을 결정함을 경험

OVERVIEW

야간 자율순찰 시스템

기간	팀 구성	담당 영역
2026.03 ~ 2026.04 (7 주)	6 인 프로젝트	Vision AI · LLM

프로젝트 개요

핵심 목표

ROS2 자율주행 로봇이 순찰 중 **Vision AI 로 이상 상황을 탐지**하고 **관제 리포트를 자동 생성**하는 스마트 보안 시스템 구축

도입 배경

야간 순찰의 인력 부족 ·CCTV 사각지대 한계를 보완하고 , 관리자의 의사결정을 지원하는 관제 시스템 구축

주요 기능

- ROS2·Gazebo 기반 자율주행 순찰
- YOLO11n · EfficientNet-B0 기반 이상 상황 탐지
- GPT-4o 기반 AI 관제 리포트 자동 생성
- React 기반 실시간 관제 대시보드

담당 역할 및 기여

- **탐지 · 분류** : 자물쇠는 YOLO11n 커스텀 학습 , 사람은 COCO 사전학습 모델 활용 , EfficientNet-B0 로 자물쇠 상태 분류 구현
- **리포트 파이프라인** : GPT 기반 AI 관제 리포트 생성 파이프라인 설계 및 구현
- **프롬프트 설계** : Markdown 기반 리포트 출력 형식 최적화
- **관제 기능** : Vision AI 와 생성형 AI 를 연계한 이상 상황 관제 구현
- **발표** : 최종 프로젝트 성과 발표

TECH STACK ROS2 / Gazebo | YOLO11n | EfficientNet-B0 | GPT-4o | FastAPI | React | PyTorch | OpenCV

DEVELOPMENT ENVIRONMENT & AI PIPELINE

개발환경 및 AI Pipeline

실행환경

Ubuntu 22.04 · ROS2 Humble
Gazebo · TurtleBot3 Waffle Pi
Python 3.10

AI 환경

Vision AI: YOLO11n, EfficientNet-B0
LLM: GPT-4o
PyTorch · OpenCV · CUDA 12.4

Backend & Frontend

Backend: FastAPI + Flask
Frontend: React 19 + Vite
Database: SQLite

AI Pipeline

1 카메라 입력
- 로봇 카메라 실시간 영상
- 순찰 환경 모니터링

2 YOLO11n
- 자물쇠 탐지 (커스텀 학습)
- 사람 감지 (COCO 사전학습)

3 EfficientNet-B0
- 자물쇠 상태 분류
- 분류 확률 (신뢰도) 출력

4 Vision 결과 구조화
- 탐지 · 분류 결과를 JSON 이벤트로 생성
- FastAPI 수신 · 검증

5 GPT-4o 리포트 생성
- 이벤트 데이터 기반 프롬프트
- 이상 상황 분석 · 리포트 생성

6 Markdown 변환
- GPT 출력 텍스트를 Markdown 형식으로 변환

7 리포트 저장
- SQLite 저장
- 이벤트 · 이미지 · 이력 관리

8 React 대시보드
- 실시간 이상 상황 자동 감지

TROUBLE SHOOTING 1

객체 탐지만으로는 자물쇠 상태 판별 한계

문제 정의 YOLO11n 만으로는 자물쇠의 **잠금 (locked) / 해제 (unlocked) 상태**를 정확하게 판별하기 어려움

원인

- Detection 모델은 객체 위치 탐지에는 적합하나 , 잠금 여부 같은 세부 상태 구분에는 한계
- 가상환경 특성상 작은 객체와 다양한 시점 변화로 오분류 발생

해결

- 자물쇠 탐지 (YOLO11n, 1 클래스 커스텀 학습) → Bounding Box 추출 → **Crop 이미지를 EfficientNet-B0 에 입력**
- Detection + Classification **2 단계 파이프라인** 설계 , Transfer Learning 기반 상태 분류 모델 적용
- 사람 감지는 COCO 사전학습 YOLO11n 을 추가 학습 없이 활용
- 분류 데이터 719 장 (locked 363 / unlocked 356, 균형 구성), 탐지 데이터 327 장 구성

결과 Detection 과 Classification 의 **역할 분리**로 자물쇠 상태 판별 정확도와 관제 리포트 신뢰도 향상

100%
상태 분류 검증 정확도
가상환경 · 검증 144 장

0.995
자물쇠 탐지 mAP50
가상환경 · 검증 65 장

TROUBLE SHOOTING 2

Vision AI 탐지 결과만으로는 관제 정보 전달 한계

문제 정의 Vision AI 탐지 결과만으로는 **이상 상황을 직관적으로 파악하기 어려움**

원인

- 사람 탐지 , 자물쇠 상태 등 개별 탐지 결과만 제공
- 이벤트 간 맥락 · 위험도 · 대응 방안 정보 부재
- 관제자가 탐지 결과를 직접 해석해야 해 관제 효율 저하

해결

- Vision AI 탐지 결과를 **구조화된 이벤트 로그**로 변환
- 순찰 결과 · 이벤트 로그 · 촬영 이미지를 GPT 프롬프트와 연계
- **Markdown 기반 AI 관제 리포트** 생성 — 상황 요약 · 위험도 · 권장 조치가 포함되도록 프롬프트 최적화

결과 탐지 결과를 관제 리포트로 자동 변환 — **상황 요약** · **위험도** · **권장 조치**를 자동 생성하여 관제자의 상황 판단과 의사결정 효율 향상

RESULT & REFLECTION

성과 및 회고

0.995

자물쇠 탐지 mAP50 (YOLO11n)
mAP50-95 0.834 · 검증 65 장
가상환경 기준

100%

자물쇠 상태 분류 Best Val Accuracy
(EfficientNet-B0)
검증 144 장 · 가상환경 기준

주요 성과

- ROS2 자율주행 순찰 ·Vision AI 관제 시스템 구현
- Vision AI + GPT 연계 **관제 리포트 자동 생성**
- 탐지부터 리포트까지 **End-to-End AI 서비스** 구현

아쉬웠던 부분

- 가상환경 (Gazebo) 데이터로 학습하여 실제 환경에 대한 일반화 성능 검증에 한계
- 별도 test set 없이 검증 데이터로 최적 epoch 를 선택해 수치가 낙관적일 수 있음

개선 방안

- 실제 환경 데이터 추가 및 train/val/test 3 분할 재평가로 일반화 성능 검증
- 다양한 LLM·Prompt 전략 비교로 리포트 품질 고도화
- RAG 기반 외부 지식 연계로 상황 분석 정확도 향상

깨달은 점

- Vision AI 와 생성형 AI 를 잇는 **데이터 구조 설계**가 중요하며 , 전달되는 정보의 형태가 서비스 품질을 결정
- 객체 탐지와 상태 분류를 **분리한 모델 설계**가 정확도 향상에 효과적

MINI PROJECT

MINI PROJECTS

단기 팀 프로젝트 2 건

M1 Smart Cart · AI 비전 기반 스마트 마트카트

M2 AI 도슨트 · 국립중앙박물관 AI 도슨트

OVERVIEW

AI 비전 기반 스마트 마트카트

기간	팀 구성	담당 영역
2026.09	5 인 (주제 · 데이터 수집 공동 진행 → 이후 개인 개발)	Backend · Vision AI 통합

프로젝트 개요

핵심 목표

카메라로 상품을 인식해 **장바구니 금액을 실시간 계산**하고 **요리를 추천**하는 스마트 카트 구현

도입 배경

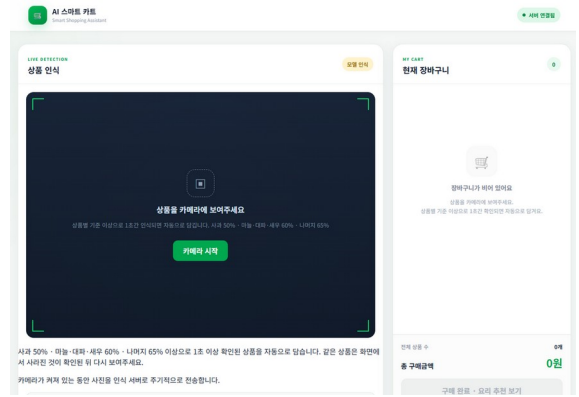
1 인 가구 증가 · 물가 상승으로 커진 장보기 예산 부담 , 구매 재료 활용 문제 해결

주요 기능

- 상품 탐지 · 자동 장바구니 등록
- 수량 · 총 금액 실시간 계산
- 보유 식재료 기반 요리 추천
- 부족 재료 자동 안내

담당 역할 및 기여

- YOLO 탐지 결과를 서비스로 연결하는 **FastAPI Backend 설계**
- 상품 · 가격 **DB 구조 설계** 및 수량 · 총 금액 계산 로직 구현
- 보유 재료를 분석하는 **요리 추천 로직** 구현
- 필요 · 보유 재료 비교로 **부족 재료 자동 추출**
- Camera → YOLO → FastAPI → DB → UI **전체 흐름 설계**



웹 서비스 화면 · 상품 인식 · 신뢰도 표시

94.7%
Precision

10 종
상품 인식

TECH STACK YOLOv8n FastAPI React SQLite Roboflow

AI PIPELINE & RESULT

AI Pipeline · 성과 · Trouble Shooting

1 웹 카메라
React 로 프레임 캡처

2 FastAPI /detect
JPEG 프레임 순차 전송

3 YOLOv8n 탐지
상품별 신뢰도 임계값 + 1 초 유지 확인

4 장바구니 API
SQLite 저장 · 수량 · 금액 계산

5 요리 추천
보유 재료 비교 · 부족 재료 안내

94.70%
Precision (임계값 튜닝 후 운영 기준)

57.66%
Recall (정밀도 우선 전략)

82.20%
mAP50

10 + 5
상품 10 종 인식 + 요리 5 종 추천 로직 통합

Trouble Shooting · FastAPI 실행 시 ASGI Application 로딩 오류

문제 : `uvicorn main:app` 실행 시 "Attribute app not found in module main" 오류
원인 : main.py 내 FastAPI 인스턴스 (app) 선언 및 엔트리포인트 모듈 구조 문제
해결 : FastAPI 인스턴스를 올바르게 선언하고 모듈 구조를 정리하여 정상 실행
결과 : Uvicorn 이 Python 모듈과 FastAPI Application 객체를 로딩하는 구조를 이해

깨달은 점

증강 · 하이퍼파라미터를 늘려도 성능이 비례해 좋아지지 않으며 , **서비스 목표 (정밀도 우선) 에 맞는 운영 지표 선택**이 더 중요함을 확인 . 정밀도 우선 전략으로 오탐 (장바구니 금액 오류) 을 최소화

OVERVIEW

국립중앙박물관 AI 도슨트

기간	팀 구성	담당 영역
2026.09 ~ 2026.10	5 인 프로젝트 (팀장)	PM · 데이터셋 구축 · 서비스 통합 · LLM 평가 설계

프로젝트 개요

핵심 목표

유물을 카메라로 비추면 **자동 인식**하고 , 관람객 유형 (어린이 / 일반 / 전문가) 별 **맞춤 해설과 실시간 Q&A** 를 제공하는 AI 도슨트

도입 배경

설명 카드만으로는 관람객 눈높이에 맞춘 해설이 어렵고 , 궁금한 점을 바로 물어볼 곳이 없음

주요 기능

- 유물 인식 (7 종)
- 관람객 유형별 해설
- 공식 데이터 기반 챗봇

담당 역할 및 기여

- **일정 · 협업** : Git 브랜치 전략 · PR 리뷰 규칙 수립
- **데이터셋 구축** : Blender synthetic 1,416 장 + 실사 66 장 확보 , 과적합 방지를 위해 real 은 val/test 위주로 배치
- **서비스 통합** : Vision · RAG · LLM · API 를 하나의 흐름으로 통합
- **LLM 평가 설계** : 4 가지 평가 (팩트체크 · 교차 · 외부 심판 · 사람 블라인드) 설계 · 실행

TECH STACK EfficientNet-B0 | Ollama (EXAONE-3.5) | GGUF Q4_K_M | RAG | FastAPI | React + Vite | SQLite

AI PIPELINE & RESULT

AI Pipeline · 성과 · Trouble Shooting

1 유형 선택
어린이 / 일반 / 전문가

2 유물 인식
카메라 촬영 → EfficientNet-B0 인식 , artifact_id 반환

3 해설 생성
공식 데이터 (GOLD) 조회 → 유형별 해설 (사전 생성본 캐시)

4 결과 화면
유물 정보 · AI 해설 표시

5 챗봇 Q&A
로컬 LLM 이 공식 데이터에 근거해 답변

99.61%
Vision 인식 정확도 (테스트 257 장 중 256 장 , macro F1 99.63%)

53 / 54
실사 촬영 정답 , 유일한 오답은 신뢰도 0.28 로 임계값 (0.60) 에서 재촬영 요청

3.5~4.3 초
LLM 평균 응답속도 (로컬 모델 4 종 비교 기준)

Trouble Shooting · 로컬 LLM 이 중국어가 섞이거나 엉뚱하게 답변

문제 : 직접 양자화한 로컬 LLM 이 한국어 질문에 중국어를 섞거나 엉뚱한 답 생성
원인 : Ollama 등록 시 채팅 템플릿 미지정 → 모델 기대 형식 (ChatML) 과 입력 불일치
해결 : 토크나이저 설정을 확인해 올바른 템플릿을 Modelfile 에 명시 후 재등록
결과 : 한국어 응답 정상화 , 신규 모델 추가 시 템플릿 우선 확인 절차 수립

깨달은 점

로컬 모델끼리 서로 채점하게 하면 자기가 만든 오답에 후한 점수를 주는 **자기 선호 편향**이 나타남 . **중립 심판 · 사람 블라인드 평가**를 함께 봐야 신뢰할 수 있는 결론이 나옴을 확인

THANK YOU

저의 잠재력을 믿고 소중한 시간을 내어 포트폴리오를 검토해 주셔서 진심으로 감사드립니다 .

귀사의 빛나는 인재가 되길 기대합니다 .

AI 엔지니어 지원자

강건재

010-4120-2283 · kgj200401@gmail.com